



中国科学院南京分院  
Nanjing Branch of Chinese Academy of Sciences

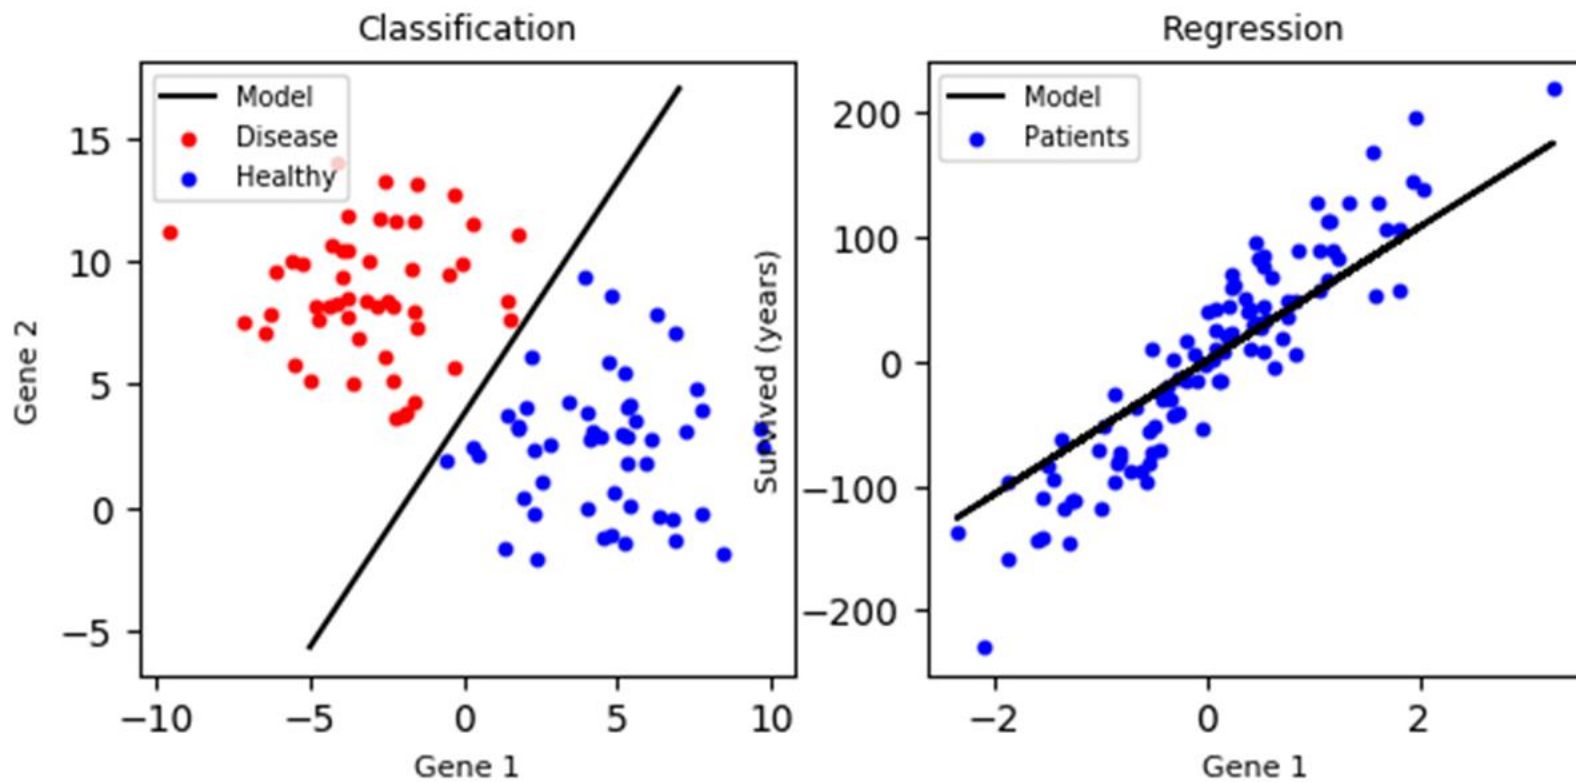
# 人工智能原理与算法

## 2. 线性回归模型

夏睿


2023.2.22

# 回归 vs. 分类




# 线性回归

Simple Linear Regression



Multiple Linear Regression  
(2 Independent Variables ( $x_1, x_2$ ))



# 输入、输出、关系

- 训练集

Living area (feet <sup>2</sup> )	#bedrooms	Price (1000\$s)
2104	3	400
1600	3	330
2400	3	369
1416	2	232
3000	4	540
⋮	⋮	⋮

一个训练样本  
 $(x^{(k)}, y^{(k)})$ , 其中  
 $k$ 表示样本索引

输入：特征向量  $x = [x_1, x_2]^T$

输出：标量 $y$

- 输入与输出的关系

$$h_{\theta}(x) = \theta_0 + \theta_1 x_1 + \theta_2 x_2$$

# 线性回归模型

- 模型假设

模型参数

$$h_{\theta}(\mathbf{x}) = \sum_{i=1}^M \theta_i x_i + \theta_0 = \theta^T \mathbf{x} \quad \text{其中 } \theta = [\theta_0, \theta_1, \dots, \theta_M]^T, \mathbf{x} = [1, x_1, \dots, x_M]^T$$

- 学习准则（损失函数）


均方误差（Mean Squared Error, MSE）

$$\begin{aligned} L_{lr}(\theta) &= \frac{1}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)})^2 \\ &= \frac{1}{N} \sum_{k=1}^N (\theta^T \mathbf{x}^{(k)} - y^{(k)})^2 \end{aligned}$$



$$\theta^* = \arg_{\theta} \min L_{lr}(\theta)$$

最小均方误差（Minimum Mean Squared Error）  
也称为最小二乘法（Least Square, LS）



# LS问题求解

- 引入矩阵表示

$$\mathbf{X} = \begin{bmatrix} -(\mathbf{x}^{(1)})^T & - \\ -(\mathbf{x}^{(2)})^T & - \\ \vdots & \\ -(\mathbf{x}^{(N)})^T & - \end{bmatrix} \quad \mathbf{y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(N)} \end{bmatrix}$$

- 从而得到

$$\mathbf{X}\boldsymbol{\theta} - \mathbf{y} = \begin{bmatrix} (\mathbf{x}^{(1)})^T \boldsymbol{\theta} \\ \vdots \\ (\mathbf{x}^{(N)})^T \boldsymbol{\theta} \end{bmatrix} - \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(N)} \end{bmatrix} = \begin{bmatrix} h(\mathbf{x}^{(1)}) - y^{(1)} \\ \vdots \\ h(\mathbf{x}^{(N)}) - y^{(N)} \end{bmatrix}$$

- 矩阵形式的损失函数

$$L_{lr}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)})^2 = \frac{1}{N} (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{y})$$

# LS解析解

- 基于矩阵形式求导

$$\begin{aligned}\nabla_{\theta} L_{lr}(\theta) &= \nabla_{\theta} \frac{1}{N} (\mathbf{X}\theta - \mathbf{y})^T (\mathbf{X}\theta - \mathbf{y}) \\ &= \frac{1}{N} \nabla_{\theta} (\theta^T \mathbf{X}^T \mathbf{X} \theta - \theta^T \mathbf{X}^T \mathbf{y} - \mathbf{y}^T \mathbf{X} \theta + \mathbf{y}^T \mathbf{y}) \\ &= \frac{2}{N} (\mathbf{X}^T \mathbf{X} \theta - \mathbf{X}^T \mathbf{y})\end{aligned}$$

矩阵求导性质: [https://en.wikipedia.org/wiki/Matrix\\_calculus](https://en.wikipedia.org/wiki/Matrix_calculus)

$$\frac{\partial (\mathbf{x}^T \mathbf{A} \mathbf{x})}{\partial (\mathbf{x})} = (\mathbf{A} + \mathbf{A}^T) \mathbf{x}$$



$$\frac{\partial (\mathbf{b}^T \mathbf{A} \mathbf{x})}{\partial (\mathbf{x})} = \mathbf{A}^T \mathbf{b}$$

- 求导置零获得解析解

$$\theta^* = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

逆矩阵常常难以计算，甚至不可逆！

# 梯度下降算法示意图





# 梯度下降算法

- 梯度下降是求函数 $L(\theta)$ 最小值的一阶迭代优化算法
- 主要思想：
  - 梯度反方向是函数值下降最快的方向
- 优化过程：
  - 从初始位置开始（即初始参数 $\theta^{(0)}$ ）
  - 在当前位置 $\theta^{(t)}$ ，重复直到收敛
    - 计算当前位置梯度： $\nabla_{\theta} L(\theta)|_{\theta=\theta^{(t)}}$
    - 沿梯度反方向移动到下一个位置： $\theta^{(t+1)} = \theta^{(t)} - \alpha \cdot \nabla_{\theta} L(\theta)|_{\theta=\theta^{(t)}}$ ，其中 $\alpha$ 是学习率
    - $t = t + 1$

# 线性回归的梯度下降

- 梯度

$$\begin{aligned}\frac{dL_{lr}(\boldsymbol{\theta})}{d\boldsymbol{\theta}} &= \frac{1}{N} \frac{d}{d\boldsymbol{\theta}} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)})^2 \\ &= \frac{2}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \cdot \frac{d}{d\boldsymbol{\theta}} (h(\mathbf{x}^{(k)}) - y^{(k)}) \\ &= \frac{2}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \frac{d}{d\boldsymbol{\theta}} (\boldsymbol{\theta}^T \mathbf{x}^{(k)}) \\ &= \frac{2}{N} \sum_{k=1}^N \boxed{(h(\mathbf{x}^{(k)}) - y^{(k)}) \mathbf{x}^{(k)}} \quad \text{误差} \cdot \text{输入}\end{aligned}$$

- 梯度下降(GD) 优化

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha \frac{d}{d\boldsymbol{\theta}} L_{lr}(\boldsymbol{\theta}) = \boldsymbol{\theta} - \alpha \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \mathbf{x}^{(k)}$$

# 从概率角度解读线性回归模型

- 假设一个具有高斯噪声的线性模型


假设  $E \sim \mathcal{N}(0, \sigma^2)$

$$p(e; \sigma) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{e^2}{2\sigma^2}\right)$$

$x$  为一个确定性取值

$$y = \boldsymbol{\theta}^T \mathbf{x} + e \sim \mathcal{N}(\boldsymbol{\theta}^T \mathbf{x}, \sigma^2)$$

$$p(y|\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \boldsymbol{\theta}^T \mathbf{x})^2}{2\sigma^2}\right)$$



对于给定的取值 $x$ ,  $y$ 服从 $\boldsymbol{\theta}^T \mathbf{x}$ 为期望、 $\sigma^2$ 为方差的高斯分布

# 最大似然估计(MLE)

- 似然函数

$$L(\boldsymbol{\theta}) = \prod_{k=1}^N p(y^{(k)} | \mathbf{x}^{(k)}; \boldsymbol{\theta}) = \prod_{k=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(k)} - \boldsymbol{\theta}^T \mathbf{x}^{(k)})^2}{2\sigma^2}\right)$$

- 对数似然

$$\begin{aligned} l(\boldsymbol{\theta}) &= \log L(\boldsymbol{\theta}) = \log \prod_{k=1}^N \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(k)} - \boldsymbol{\theta}^T \mathbf{x}^{(k)})^2}{2\sigma^2}\right) \\ &= \sum_{k=1}^N \log \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y^{(k)} - \boldsymbol{\theta}^T \mathbf{x}^{(k)})^2}{2\sigma^2}\right) \\ &= N \log \frac{1}{\sqrt{2\pi}\sigma} - \frac{1}{\sigma^2} \cdot \frac{1}{2} \sum_{k=1}^N (y^{(k)} - \boldsymbol{\theta}^T \mathbf{x}^{(k)})^2 \end{aligned}$$

- 最大化对数似然函数

$$\max l(\boldsymbol{\theta}) \Leftrightarrow \min \frac{1}{N} \sum_{k=1}^N (y^{(k)} - \boldsymbol{\theta}^T \mathbf{x}^{(k)})^2$$

**MLE = LS**

# 回归任务的性能评估

- Mean Squared Error (MSE)

$$\text{MSE}_{te} = \frac{1}{N_{te}} \sum_{k=1}^{N_{te}} \left( h(\mathbf{x}_{te}^{(k)}) - y_{te}^{(k)} \right)^2 = \frac{1}{N_{te}} \sum_{k=1}^{N_{te}} \left( \boldsymbol{\theta}^{*T} \mathbf{x}_{te}^{(k)} - y_{te}^{(k)} \right)^2$$

- Mean Absolute Error (MAE)

$$\text{MAE}_{te} = \frac{1}{N_{te}} \sum_{k=1}^{N_{te}} \left| h(\mathbf{x}_{te}^{(k)}) - y_{te}^{(k)} \right| = \frac{1}{N_{te}} \sum_{k=1}^{N_{te}} \left| \boldsymbol{\theta}^{*T} \mathbf{x}_{te}^{(k)} - y_{te}^{(k)} \right|$$

- R Squared ( $R^2$ )

$$R^2_{te} = 1 - \frac{\text{SS}_{residual}}{\text{SS}_{total}} = 1 - \frac{\sum_{k=1}^{N_{te}} \left( y_{te}^{(k)} - h(\mathbf{x}_{te}^{(k)}) \right)^2}{\sum_{k=1}^{N_{te}} \left( y_{te}^{(k)} - \bar{y}_{te} \right)^2}$$

# 作业#1：南京房价预测

- 给定南京平均房价历史数据

Year  $x$  = [2000, 2001, 2002, 2003, 2004, 2005, 2006, 2007, 2008, 2009, 2010, 2011, 2012, 2013]

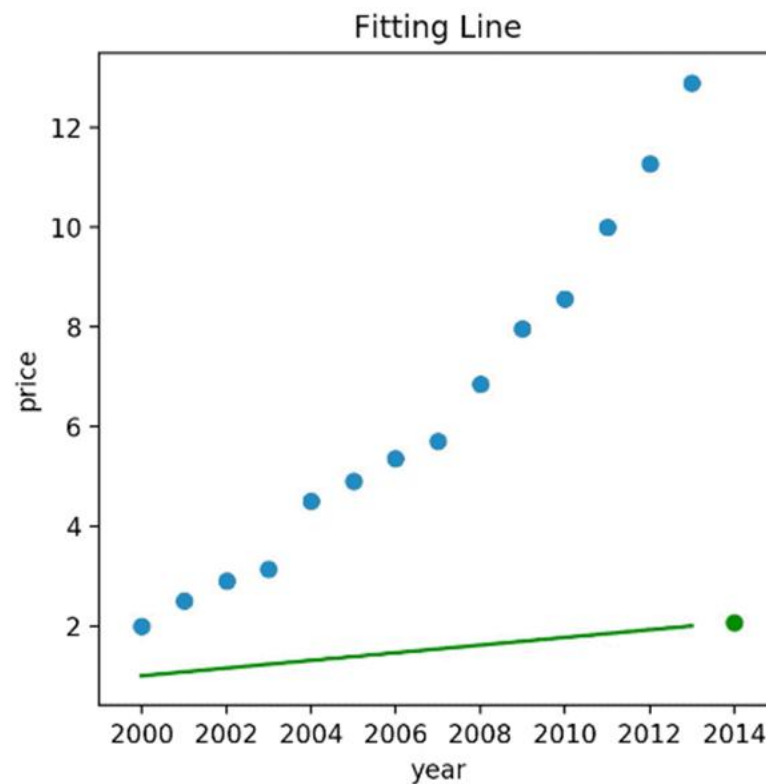
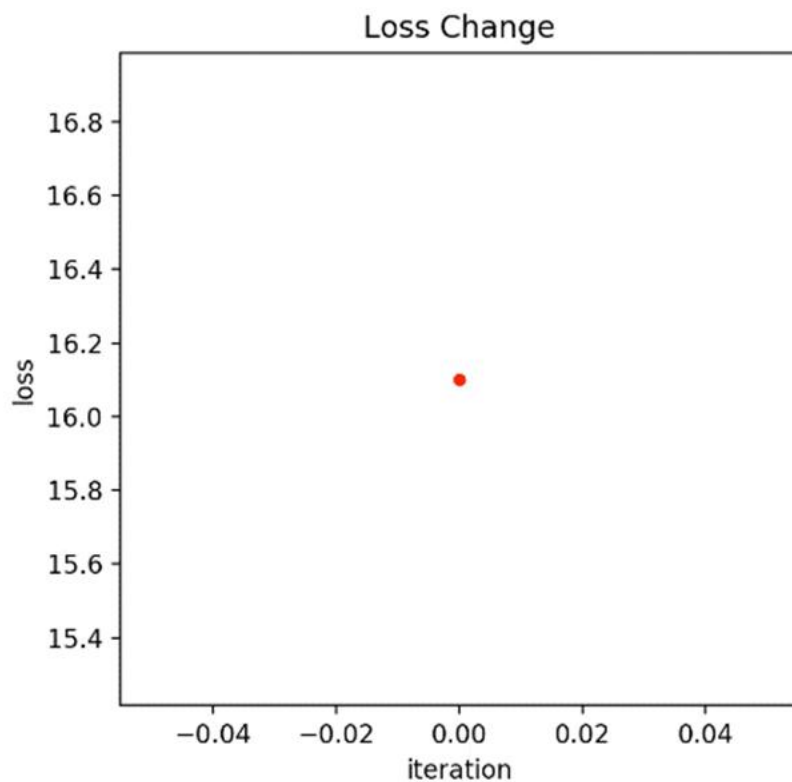
Price  $y$  = [2.000, 2.500, 2.900, 3.147, 4.515, 4.903, 5.365, 5.704, 6.853, 7.971, 8.561, 10.000, 11.280, 12.900]

<http://www.nustm.cn/member/rxia/ml/data/Price.zip>

- 假设：房价和年度呈线性关系
- 任务：基于下列两种方法编程实现线性回归：1) 解析解；2) 梯度下降法，获得 $x$ 和 $y$ 的关系，并预测2014年的南京房价

# Demo

Linear Regression - Gradient Descent





**本讲结束 欢迎提问**