



中国科学院南京分院
Nanjing Branch of Chinese Academy of Sciences

人工智能原理与算法

4. 感知机

夏睿

2023.3.1

目录

- （二分类）感知机
- 多分类感知机
- 线性模型回顾

感知机


感知机（Perceptron）




- 感知机算法是Frank Rosenblatt于1957年就职于康奈尔航空实验室时所发明的。
- 感知机是一种监督分类算法。
- 它是一种线性分类算法。
- 它是人工神经网络（ANN）的早期代表性工作，奠定了ANN的基础。

从神经网络到人工神经网络

神经元



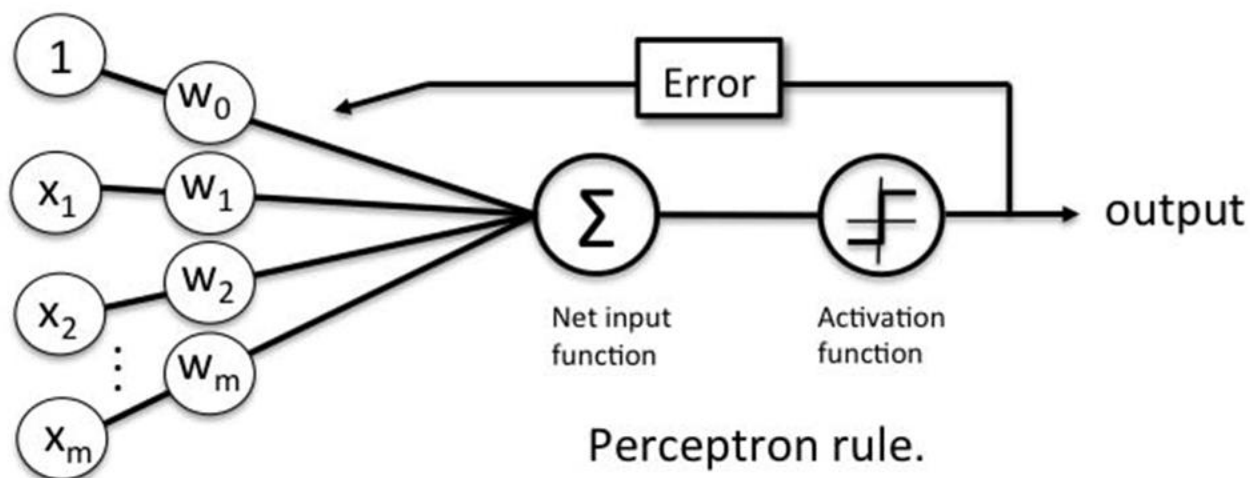
人工神经元



感知机模型

- 模型假设

$$h(\mathbf{x}) = \text{sgn}(\boldsymbol{\omega}^T \mathbf{x}) = \begin{cases} 1 & \text{if } \boldsymbol{\omega}^T \mathbf{x} \geq 0 \\ 0 & \text{if } \boldsymbol{\omega}^T \mathbf{x} < 0 \end{cases}$$



感知机学习算法

- 感知机损失函数

$$\begin{aligned}l_p(\omega) &= \sum_{\mathbf{x}^{(h)} \in M_0} \omega^T \mathbf{x}^{(h)} - \sum_{\mathbf{x}^{(l)} \in M_1} \omega^T \mathbf{x}^{(l)} && M_0: \text{真实标签为负类、预测标签为正类} \\&&& M_1: \text{真实标签为正类、预测标签为负类} \\&= \sum_{k=1}^N \left((1 - y^{(k)}) h(\mathbf{x}^{(k)}) - y^{(k)} (1 - h(\mathbf{x}^{(k)})) \right) \omega^T \mathbf{x}^{(k)} \\&= \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \omega^T \mathbf{x}^{(k)}\end{aligned}$$

- 梯度计算

$$\begin{aligned}\frac{dl_p(\omega)}{d\omega} &= \frac{1}{N} \frac{d}{d\omega} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \omega^T \mathbf{x}^{(k)} \\&= \frac{1}{N} \sum_{k=1}^N \boxed{(h(\mathbf{x}^{(k)}) - y^{(k)}) \mathbf{x}^{(k)}} && \text{误差} \cdot \text{输入}\end{aligned}$$

(随机) 梯度下降





- 梯度下降(GD)

$$\boldsymbol{\omega} \leftarrow \boldsymbol{\omega} - \alpha \frac{d}{d\boldsymbol{\omega}} l_P(\boldsymbol{\omega}) = \boldsymbol{\omega} - \alpha \frac{1}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \mathbf{x}^{(k)}$$

- 随机梯度下降(SGD)

$$\begin{aligned} \boldsymbol{\omega} &\leftarrow \boldsymbol{\omega} - \alpha (h(\mathbf{x}) - y) \mathbf{x} \\ &= \begin{cases} \boldsymbol{\omega} + \alpha \mathbf{x}, & \text{if } y = 1 \text{ and } h(\mathbf{x}) = 0 \\ \boldsymbol{\omega} - \alpha \mathbf{x}, & \text{if } y = 0 \text{ and } h(\mathbf{x}) = 1 \\ \boldsymbol{\omega}, & \text{otherwise} \end{cases} \end{aligned}$$

感知机算法图释



感知机手算

- 训练集

样本序号	特征向量 (x_1, x_2)	真实类别 y
1	(-0.8, 0.6)	0
2	(-0.55, 0.7)	0
3	(-0.4, 0.7)	0
4	(-0.1, -0.2)	0
5	(-0.75, 0.95)	0
6	(0.2, 0.75)	1
7	(0.9, 0.9)	1
8	(0.45, 0.3)	1
9	(0.4, -0.5)	1
10	(0.6, -0.9)	1

- 运行一个感知机学习算法（不含偏置项）

$$h(\mathbf{x}) = \begin{cases} 1 & \text{if } \omega_1 x_1 + \omega_2 x_2 \geq 0 \\ 0 & \text{otherwise} \end{cases}$$

感知机手算

- 初始化：设置初始权重为 $\mathbf{w}^{(0)} = (-0.5, -1)$ ，并且固定学习率 $\alpha = 1$ 。
- 预测阶段：根据 $\mathbf{w}^{(0)}$ 进行预测。

样本序号	特征向量 (x_1, x_2)	真实类别 y	预测类别 $h(\mathbf{x})$
1	(-0.8, 0.6)	0	
2	(-0.55, 0.7)	0	
3	(-0.4, 0.7)	0	
4	(-0.1, -0.2)	0	
5	(-0.75, 0.95)	0	
6	(0.2, 0.75)	1	
7	(0.9, 0.9)	1	
8	(0.45, 0.3)	1	
9	(0.4, -0.5)	1	
10	(0.6, -0.9)	1	

观察表格，我们可以发现样本 _____ 分类错误。

感知机手算

- 权重更新阶段：我们随机选择一个错分样本，如第6个样本 (0.2, 0.75)，用于更新权重。权重更新公式：

$$\begin{aligned}\omega &\leftarrow \omega - \alpha(h(\mathbf{x}) - y)\mathbf{x} \\ &= \begin{cases} \omega + \mathbf{x}, & \text{if } y = 1 \text{ and } h(\mathbf{x}) = 0 \\ \omega - \mathbf{x}, & \text{if } y = 0 \text{ and } h(\mathbf{x}) = 1 \\ \omega, & \text{otherwise} \end{cases}\end{aligned}$$

我们可以得到新的权重 $\mathbf{w}^{(1)} =$ _____。

感知机手算

- 预测阶段：根据 $w^{(1)}$ 进行预测。

样本序号	特征向量 (x_1, x_2)	真实类别 y	预测类别 $h(x)$
1	(-0.8, 0.6)	0	
2	(-0.55, 0.7)	0	
3	(-0.4, 0.7)	0	
4	(-0.1, -0.2)	0	
5	(-0.75, 0.95)	0	
6	(0.2, 0.75)	1	
7	(0.9, 0.9)	1	
8	(0.45, 0.3)	1	
9	(0.4, -0.5)	1	
10	(0.6, -0.9)	1	

观察表格，我们可以发现样本 _____ 分类错误。

- 权重更新阶段：我们随机选择一个错分样本，比如第8个样本 (0.45, 0.3) 用于更新权重，得到新的权重 $w^{(2)} =$ _____。

感知机手算

- 预测阶段：根据 $w^{(2)}$ 进行预测。

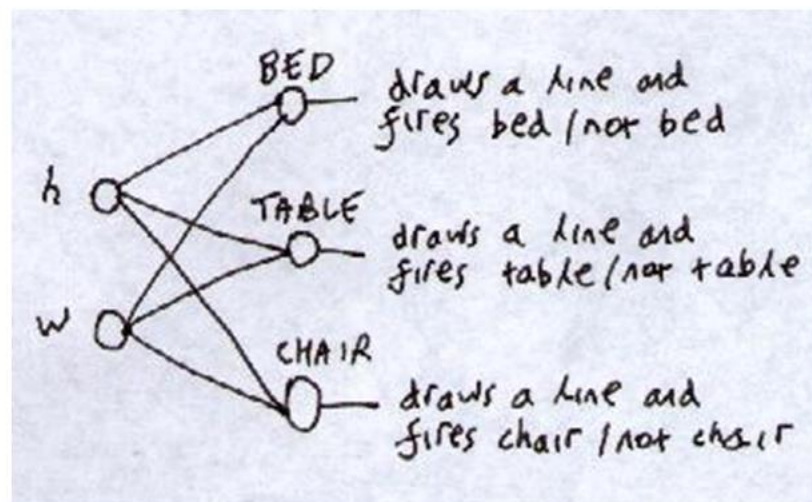

样本序号	特征向量 (x_1, x_2)	真实类别 y	预测类别 $h(x)$
1	(-0.8, 0.6)	0	
2	(-0.55, 0.7)	0	
3	(-0.4, 0.7)	0	
4	(-0.1, -0.2)	0	
5	(-0.75, 0.95)	0	
6	(0.2, 0.75)	1	
7	(0.9, 0.9)	1	
8	(0.45, 0.3)	1	
9	(0.4, -0.5)	1	
10	(0.6, -0.9)	1	

感知机算法现在收敛了吗？

多分类感知机

多分类感知机模型

- 多类感知机（multi-class perceptron）是标准感知机的扩展，用于解决多类分类问题；
- 多类感知机广泛应用于 NLP。



假设与学习

- 假设

$$h(\mathbf{x}) = \arg \max_{j=1,\dots,C} \boldsymbol{\omega}_j^T \mathbf{x}$$

- 损失函数

$$l_p(\boldsymbol{\omega}) = \sum_{k=1}^N \left(\max_{j=1,\dots,C} \boldsymbol{\omega}_j^T \mathbf{x}^{(k)} - \boldsymbol{\omega}_{y^{(k)}}^T \mathbf{x}^{(k)} \right) = \sum_{k=1}^N \left(\boldsymbol{\omega}_{h(\mathbf{x}^{(k)})}^T \mathbf{x}^{(k)} - \boldsymbol{\omega}_{y^{(k)}}^T \mathbf{x}^{(k)} \right)$$

- 随机梯度下降参数更新

$$\boldsymbol{\omega}_j \leftarrow \boldsymbol{\omega}_j - \alpha \left(I(j = h(\mathbf{x})) - I(j = y) \right) \mathbf{x}$$

$$= \begin{cases} \boldsymbol{\omega}_j - \alpha \mathbf{x}, & \text{if } j = h(\mathbf{x}) \neq y \\ \boldsymbol{\omega}_j + \alpha \mathbf{x}, & \text{if } j = y \neq h(\mathbf{x}) \\ \boldsymbol{\omega}_j, & \text{otherwise} \end{cases}$$

线性模型回顾

模型假设（二分类）

- 线性回归

$$h_{\theta}(\mathbf{x}) = \theta^T \mathbf{x}$$

- 感知机



$$h_{\theta}(\mathbf{x}) = \begin{cases} 1, & \text{if } \theta^T \mathbf{x} \geq 0 \\ 0, & \text{if } \theta^T \mathbf{x} < 0 \end{cases}$$

- Logistic回归


$$P(y = 1|\mathbf{x}; \theta) = \delta(\theta^T \mathbf{x}) = \frac{1}{1 + e^{-\theta^T \mathbf{x}}}$$

$$P(y = 0|\mathbf{x}; \theta) = 1 - \delta(\theta^T \mathbf{x})$$


从激活函数角度的理解



感知机的激活函数



单层人工神经网络



Logistic回归的激活函数

模型学习 – 损失函数

- 线性回归

$$L_{lr}(\boldsymbol{\theta}) = \frac{1}{N} \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)})^2$$

Least Square = Maximum Likelihood

- 感知机

$$L_p(\boldsymbol{\theta}) = \sum_{\mathbf{x}^{(k)} \in M_0} \boldsymbol{\theta}^T \mathbf{x}^{(k)} - \sum_{\mathbf{x}^{(k)} \in M_1} \boldsymbol{\theta}^T \mathbf{x}^{(k)} = \sum_{\mathbf{x}^{(k)} \in M} |\boldsymbol{\theta}^T \mathbf{x}^{(k)}|$$

Perceptron Criterion

- Logistic回归

$$L(\boldsymbol{\theta}) = \sum_{k=1}^N y^{(k)} \log h(\mathbf{x}^{(k)}) + (1 - y^{(k)}) \log (1 - h(\mathbf{x}^{(k)}))$$

Maximum Likelihood = Minimum Cross Entropy

模型学习 – 最优化

- 线性回归

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha \frac{d}{d\boldsymbol{\theta}} J_l(\boldsymbol{\theta}) = \boldsymbol{\theta} - \alpha \sum_{k=1}^N (h(\mathbf{x}^{(k)}) - y^{(k)}) \mathbf{x}^{(k)}$$

- 感知机

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} - \alpha (h(\mathbf{x}) - y) \mathbf{x} = \begin{cases} \boldsymbol{\theta} + \alpha \mathbf{x}, & \text{if } y = 1 \text{ and } h(\mathbf{x}) = 0 \\ \boldsymbol{\theta} - \alpha \mathbf{x}, & \text{if } y = 0 \text{ and } h(\mathbf{x}) = 1 \\ \boldsymbol{\theta}, & \text{otherwise} \end{cases}$$

- Logistic回归

$$\boldsymbol{\theta} \leftarrow \boldsymbol{\theta} + \alpha \sum_{k=1}^N (y^{(k)} - h_{\boldsymbol{\theta}}(\mathbf{x}^{(k)})) \mathbf{x}^{(k)}$$

模型假设（多分类）

- Softmax回归

$$p(y = j|\mathbf{x}; \boldsymbol{\theta}) = h_j(\mathbf{x}) = \frac{e^{\boldsymbol{\theta}_j^T \mathbf{x}}}{\sum_{j'=1}^C e^{\boldsymbol{\theta}_{j'}^T \mathbf{x}}}, j = 1, 2, \dots, C$$

- 多分类感知机

$$h(\mathbf{x}) = \arg \max_{j=1, \dots, C} \boldsymbol{\theta}_j^T \mathbf{x}$$

模型学习 – 损失函数

- Softmax回归

$$L(\boldsymbol{\theta}) = \sum_{k=1}^N \log p(y^{(k)} | \mathbf{x}^{(k)}; \boldsymbol{\theta}) = \sum_{k=1}^N \sum_{j=1}^C I(y^{(k)} = j) \log \left(\frac{e^{\boldsymbol{\theta}_j^T \mathbf{x}}}{\sum_{j'=1}^C e^{\boldsymbol{\theta}_{j'}^T \mathbf{x}}} \right)$$

- 多分类感知机

$$L_{mp}(\boldsymbol{\theta}) = \sum_{k=1}^N \left(\max_{j=1, \dots, C} \boldsymbol{\theta}_j^T \mathbf{x}^{(k)} - \boldsymbol{\theta}_{y^{(k)}}^T \mathbf{x}^{(k)} \right)$$

模型学习 – 最优化

- Softmax回归

$$\boldsymbol{\theta}_j \leftarrow \boldsymbol{\theta}_j + \alpha \sum_{k=1}^N \left(I(y^{(k)} = j) - h_j(\mathbf{x}^{(k)}) \right) \mathbf{x}^{(k)}$$

- 多分类感知机

$$\boldsymbol{\theta}_j \leftarrow \boldsymbol{\theta}_j - \alpha \left(I(j = h(\mathbf{x})) - I(j = y) \right) \mathbf{x} = \begin{cases} \boldsymbol{\theta}_j - \alpha \mathbf{x}, & \text{if } j = h(\mathbf{x}) \neq y^{(k)} \\ \boldsymbol{\theta}_j + \alpha \mathbf{x}, & \text{if } j = y^{(k)} \neq h(\mathbf{x}) \\ \boldsymbol{\theta}_j, & \text{otherwise} \end{cases}$$



本讲结束 欢迎提问